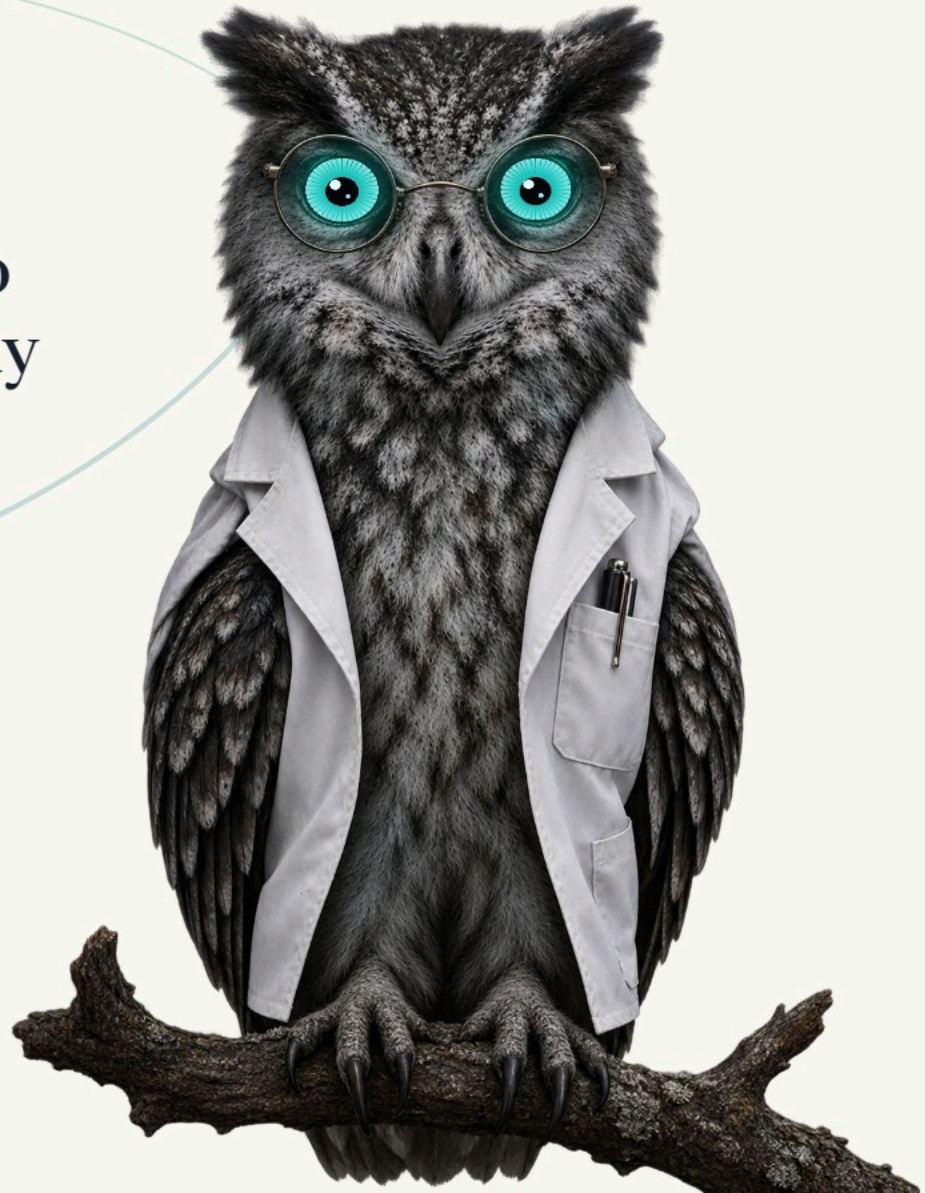
Industrial University of Ho Chi Minh City

TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN · NGÀNH KHOA HỌC DỮ LIỆU

BÁO CÁO KHÓA LUẬN TỐT NGHIỆP

Nghiên cứu và xây dựng hệ thống phát hiện ảo giác cho mô hình ngôn ngữ lớn tăng cường truy xuất tiếng Việt *dựa trên tín hiệu chú ý nội tại*



SINH VIÊN THỰC HIỆN
Nguyễn Ngọc Lân
MSSV 22635801

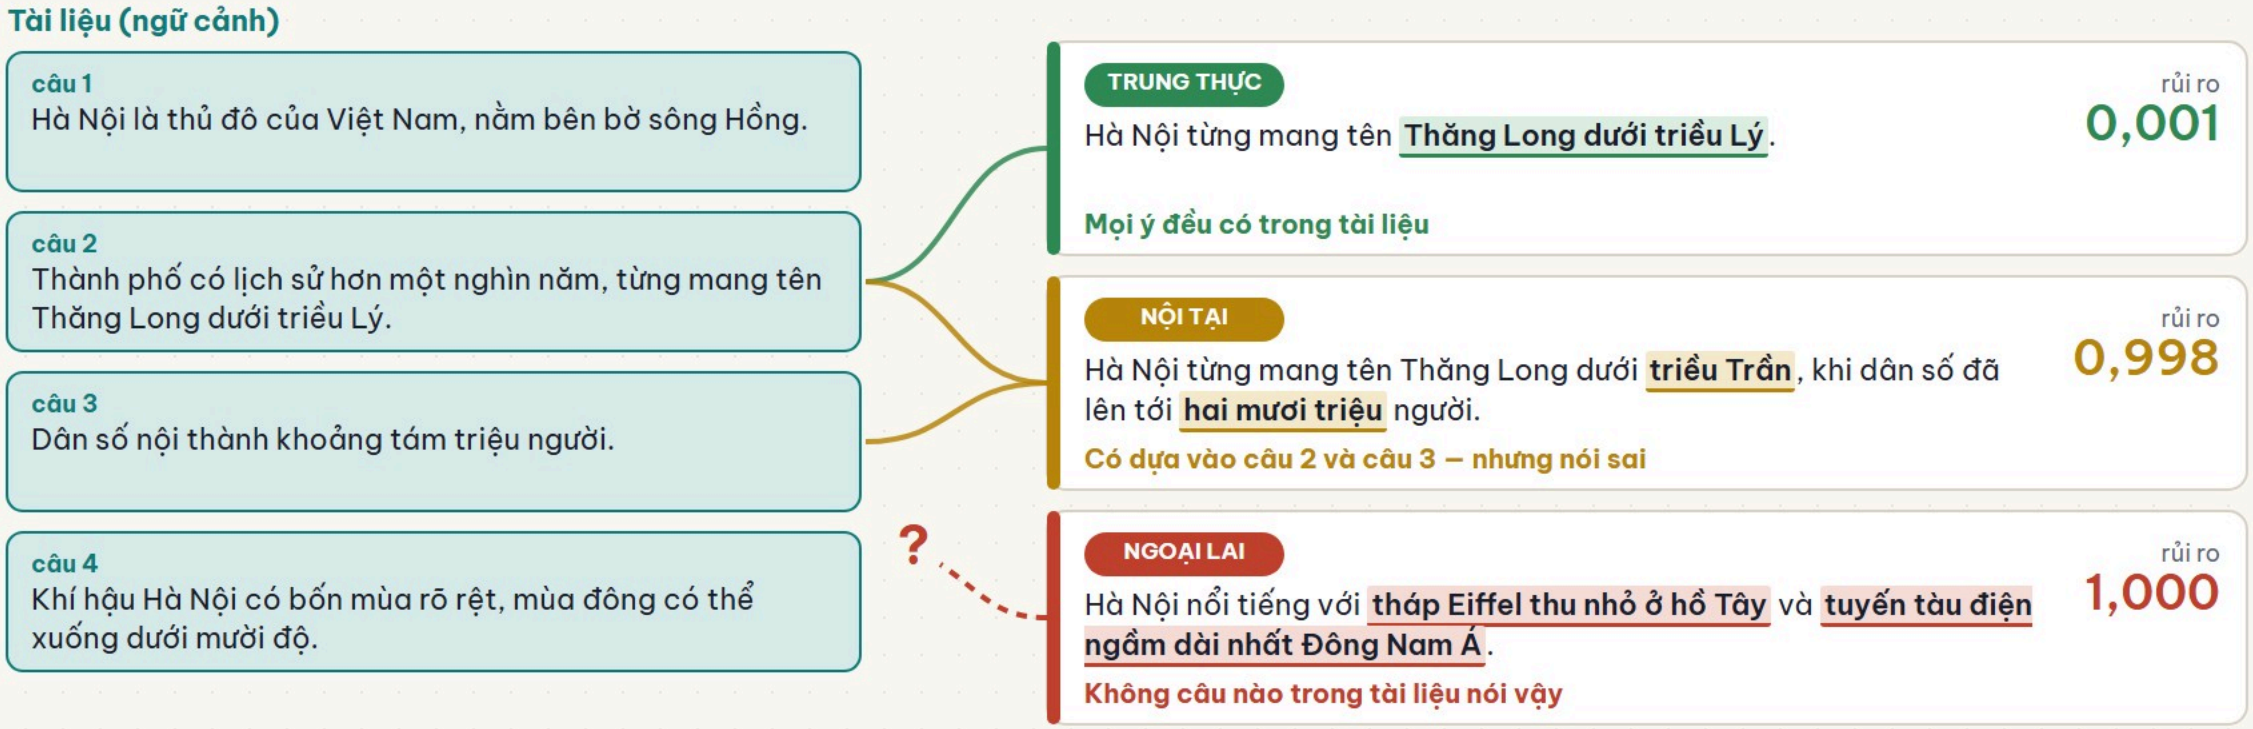
SINH VIÊN THỰC HIỆN
Nguyễn Tấn Minh
MSSV 22643511

GIẢNG VIÊN HƯỚNG DẪN
ThS. Trương Vĩnh Linh
Khoa Công nghệ Thông tin

TP. Hồ Chí Minh · 2026

Có hai kiểu bịa: đọc rồi nói sai, và không đọc mà tự thêm vào

THUẬT NGỮ **Ảo giác nội tại** — có dựa vào tài liệu nhưng nói sai so với nó. **Ảo giác ngoại lai** — nói điều tài liệu không hề có.

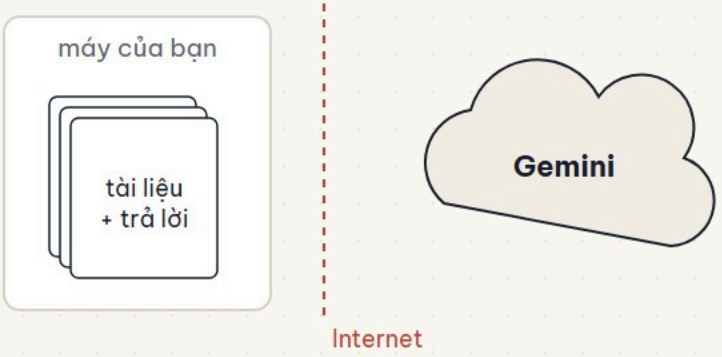


Hệ thống của đề tài chấm rủi ro cho ba câu: **0,001 · 0,998 · 1,000**. Bài toán là tách được cả ba loại, không chỉ đúng hay sai.

Phân loại: Ji và cộng sự (ACM CSUR 2023); Maynez và cộng sự (ACL 2020) · nhãn theo ViHallu (Nguyen và cộng sự, 2026) · mục 2.3

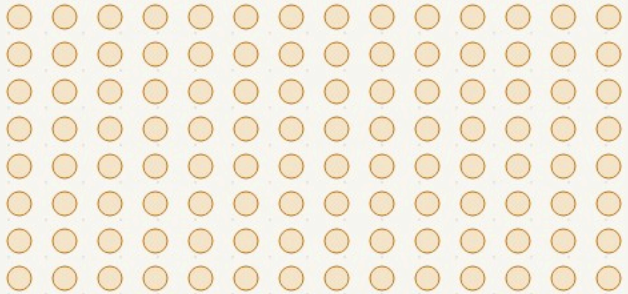
Động lực: các cách bắt ảo giác hiện nay đều phải trả một cái giá lớn

Hỏi một LLM khác làm giám khảo



- 8,2 giây cho mỗi câu trả lời
- Dữ liệu phải gửi ra khỏi máy
- macro-F1 0,664

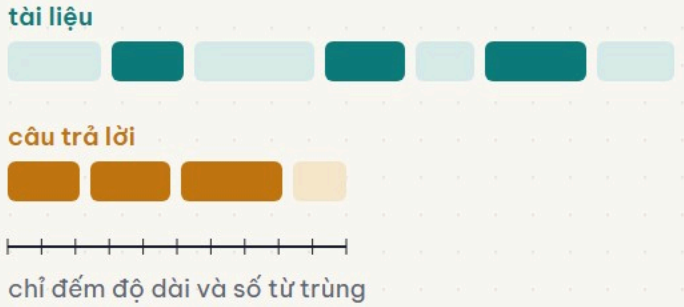
Tinh chỉnh một bộ mã hóa lớn



mỗi chấm ≈ 5 triệu tham số phải cập nhật

- 560 triệu tham số phải huấn luyện
- Cần GPU; InfoXLM không hội tụ
- macro-F1 0,776 — cao nhất

Đặc trưng bề mặt



- Chỉ 9 tham số, chạy tức thì
- Không đọc được ý nghĩa
- macro-F1 0,656 — yếu

Đề tài: dùng chú ý — thứ đã có sẵn khi mô hình đọc. Không giám khảo, không tinh chỉnh mô hình lớn, dữ liệu không rời máy.

Đề tài tìm một tín hiệu **có sẵn trong chính lượt đọc** của mô hình: không cần giám khảo, không tinh chỉnh mô hình lớn, dữ liệu không rời khỏi máy.

LLM giám khảo: Zheng và cộng sự (NeurIPS 2023) · PhoBERT: Nguyen và Nguyen (Findings EMNLP 2020) · XLM-R: Conneau và cộng sự (ACL 2020) · Bảng 6.1, 6.14

Khoảng trống nghiên cứu và ba câu hỏi của đề tài

KHOẢNG TRỐNG 1

Chưa ai tách tỷ lệ chú ý theo *từng đoạn* ngữ cảnh và kiểm chứng nó có trùng vị trí bằng chứng không.

Lookback Lens gộp cả ngữ cảnh thành một khối, nên không biết mô hình nhìn đúng đoạn hay nhìn dàn trải.

↓

CÂU HỎI 1 · TÍN HIỆU

Chú ý theo đoạn có cải thiện việc phát hiện ảo giác so với tỷ lệ gộp — và mô hình có thật sự nhìn vào đúng chỗ?

Trả lời ở slide 12–15

KHOẢNG TRỐNG 2

Chưa ai đặt ba hướng tiếp cận lên *cùng một thang đo* gồm cả độ chính xác lẫn chi phí.

Bộ mã hóa tinh chỉnh, LLM giám khảo và hướng nội tại thường được báo cáo trên dữ liệu và cách chia tập khác nhau.

↓

CÂU HỎI 2 · CHI PHÍ

So với LLM giám khảo và bộ mã hóa tinh chỉnh, hướng này đứng ở đâu về độ chính xác lẫn chi phí?

Trả lời ở slide 3 và 16

KHOẢNG TRỐNG 3

Chưa có công trình nào dùng tín hiệu nội tại để phát hiện ảo giác *tiếng Việt*.

Các hệ thống của cuộc thi ViHallu và SemViQA đều khai thác văn bản: bộ mã hóa, LLM với prompt, truy xuất bằng chứng.

↓

CÂU HỎI 3 · CHUYỂN GIAO

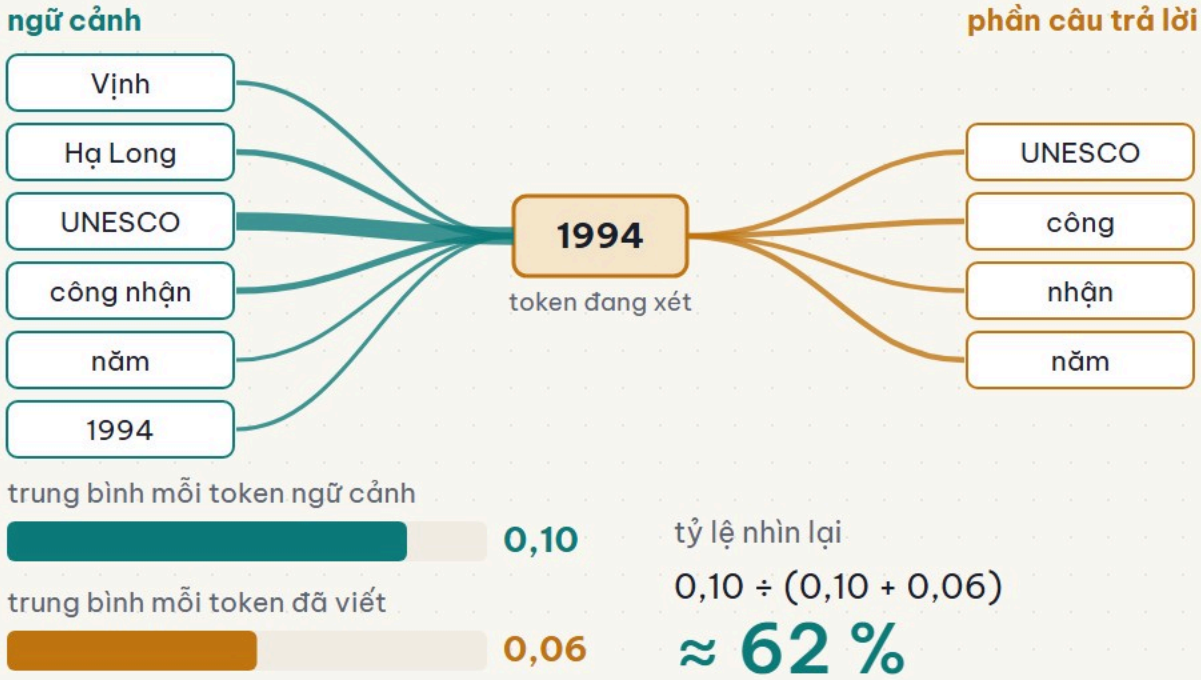
Tín hiệu chú ý thêm được bao nhiêu so với đặc trưng bề mặt, và có dùng được trên bộ dữ liệu khác không?

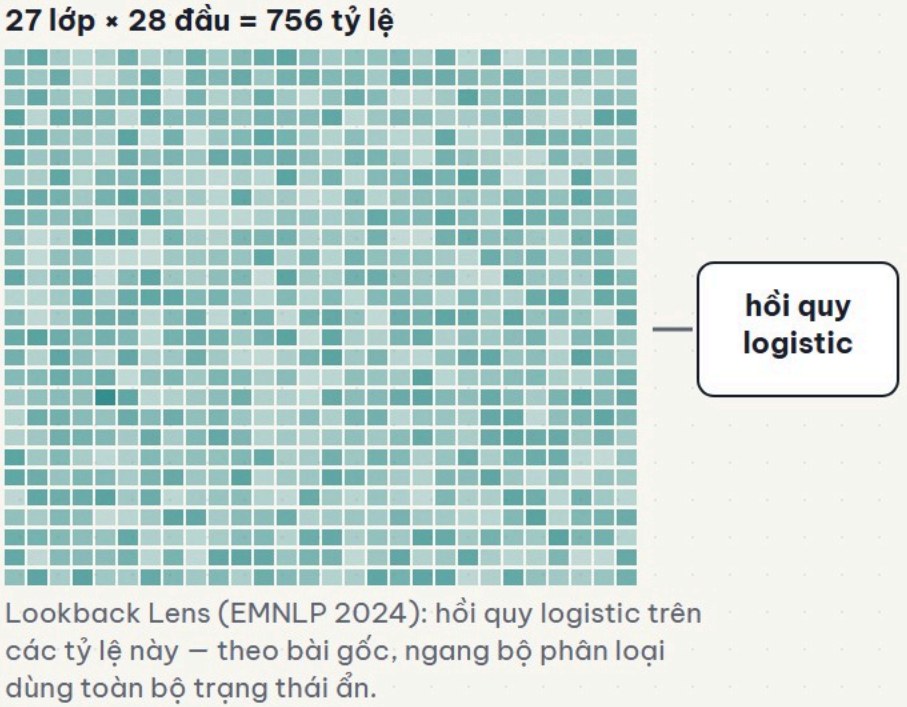
Trả lời ở slide 15 và 17

Mục 1.2–1.3 báo cáo · Lookback Lens: Chuang và cộng sự (EMNLP 2024) · ViHallu: Nguyen và cộng sự (2026) · SemViQA: Tran và cộng sự (2025) · năm giả thuyết ở Bảng 1.1

Lookback Lens gói chú ý thành một con số: nhìn tài liệu nhiều hay nhìn câu trả lời của chính mình nhiều

THUẬT NGỮ **Tỷ lệ nhìn lại (lookback ratio)** — phần chú ý dành cho ngữ cảnh chia cho tổng chú ý dành cho ngữ cảnh và cho phần câu trả lời đã viết.





Lookback Lens (EMNLP 2024): hồi quy logistic trên các tỷ lệ này — theo bài gốc, ngang bộ phân loại dùng toàn bộ trạng thái ẩn.

Một **bộ phân loại tuyến tính** đọc 756 con số đó để đoán câu trả lời có ảo giác hay không. Đây là phương pháp nền mà đề tài tái lập trên tiếng Việt.

Phương pháp nền: Chuang và cộng sự, "Lookback Lens", EMNLP 2024 · minh họa nguyên lý · mục 2.5 và 4.3

Ba bộ dữ liệu tiếng Việt, chia theo ngữ cảnh để mô hình không được "học thuộc đề"

THUẬT NGỮ **Chia theo ngữ cảnh** — mọi câu trả lời dựa trên cùng một tài liệu phải nằm chung một tập: huấn luyện, kiểm định hoặc kiểm tra.

ViHallu — 7.000 mẫu
bộ chính · câu trả lời do GPT-4o viết · 3 nhãn
trung vị 5 câu mỗi ngữ cảnh

ISE-DSC01 — 36.369 mẫu
ngữ cảnh dài · có đánh dấu câu bằng chứng
trung vị 19 câu mỗi ngữ cảnh

ViWikiFC — 20.919 mẫu
đối chứng ngoài · Wikipedia · có câu bằng chứng
trung vị 4 câu mỗi ngữ cảnh

Bẫy đã đo trước khi dùng: tập kiểm tra gốc của ViWikiFC dùng lại **100 %** ngữ cảnh của tập huấn luyện.

Chia ngẫu nhiên | Chia theo ngữ cảnh

8 tài liệu, mỗi tài liệu vài câu trả lời (cùng màu)

TL 1 TL 2 TL 3 TL 4 TL 5 TL 6 TL 7 TL 8

Chia theo ngữ cảnh: rò rỉ 0 %



Huấn luyện 80 % | Kiểm định 10 % | Kiểm tra 10 %

Kiểm tra cả các bộ có sẵn cách chia: tập kiểm tra gốc của ViWikiFC dùng lại **100 %** ngữ cảnh huấn luyện — nên điểm trên tập đó chỉ đo việc phân loại trên ngữ cảnh đã thấy.

ViHallu: Nguyen và cộng sự (2026) · ISE-DSC01: UIT DSC 2023 · ViWikiFC: Le và cộng sự (2024) · Bảng 3.1, 3.2, 3.4, 3.5

Phương pháp đề xuất: không chỉ hỏi mô hình nhìn tài liệu bao nhiêu, mà hỏi nhìn vào đoạn nào

THUẬT NGỮ **Đoạn** — một câu của ngữ cảnh. **Chunk-aware** — cộng chú ý theo từng đoạn để thấy hình dạng của nó.

câu 1
Vịnh Hạ Long nằm ở tỉnh Quảng Ninh.

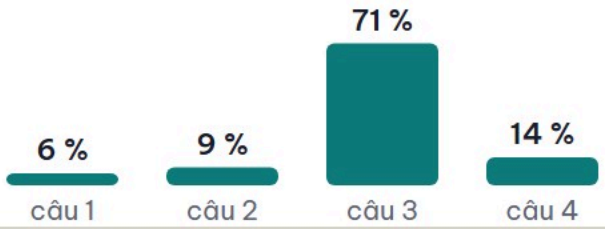
câu 2
Vịnh gồm 1.969 hòn đảo lớn nhỏ.

câu 3
UNESCO công nhận vịnh là Di sản thiên nhiên thế giới lần đầu năm 1994.

câu 4
Năm 2000, vịnh được công nhận lần thứ hai về giá trị địa chất.

A · trung thực *"UNESCO công nhận vịnh là Di sản thiên nhiên thế giới năm 1994."*

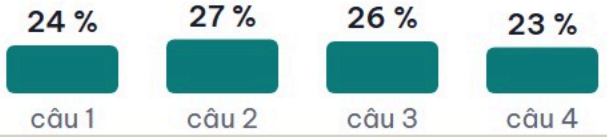
Lookback Lens · tỷ lệ nhìn ngữ cảnh **62 %**



entropy **0,65** · lớn nhất **71 %**
dồn một chỗ — nhọn

B · ngoại lai (bịa) *"Vịnh Hạ Long mỗi năm đón hơn bảy triệu lượt khách."*

Lookback Lens · tỷ lệ nhìn ngữ cảnh **62 %**



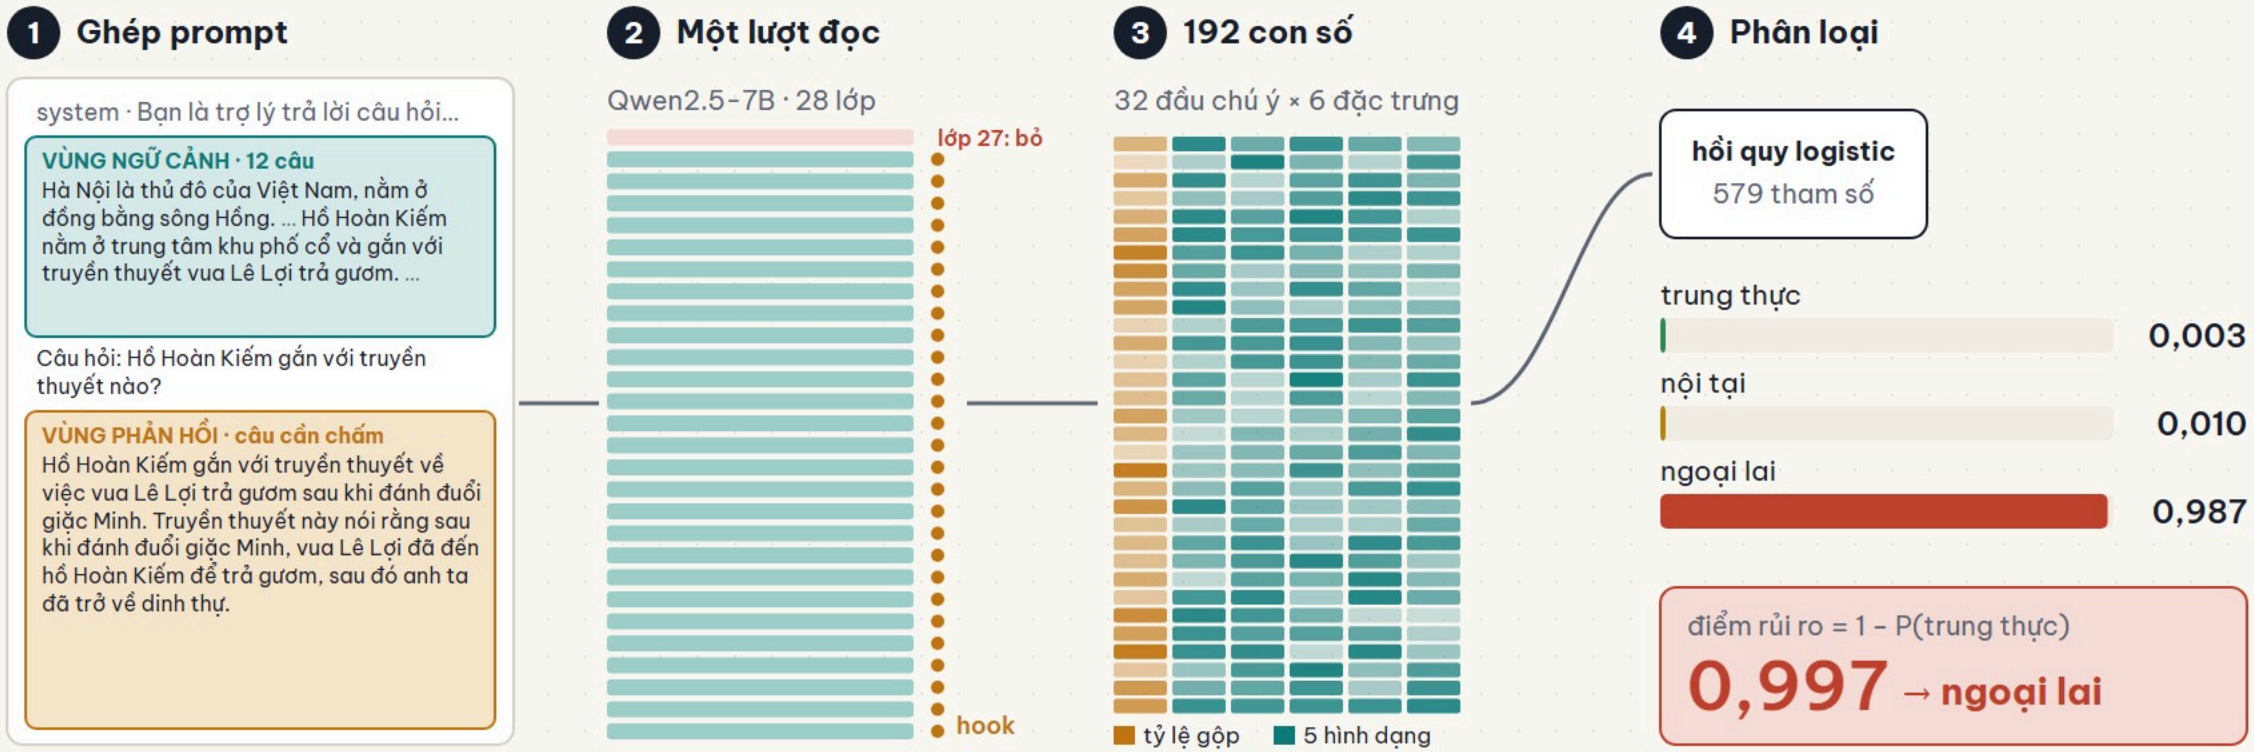
entropy **1,00** · lớn nhất **27 %**
rải đều — tản

Hình dạng được đo bằng con số: **entropy** (0 là dồn một chỗ, 1 là rải đều) và **tỷ trọng lớn nhất**. Cùng ba đại lượng khác, đó là năm đặc trưng của đề tài.

Mở rộng từ Lookback Lens (Chuang và cộng sự, EMNLP 2024) · minh họa nguyên lý, số liệu như Hình 2.1 · mục 4.4–4.5

Cả quy trình chỉ cần một lượt đọc — mô hình không phải viết thêm chữ nào

THUẬT NGỮ **Teacher forcing** — đưa sẵn câu trả lời cho mô hình đọc, thay vì để nó tự sinh; nhờ vậy chấm được câu trả lời của bất kỳ ai.



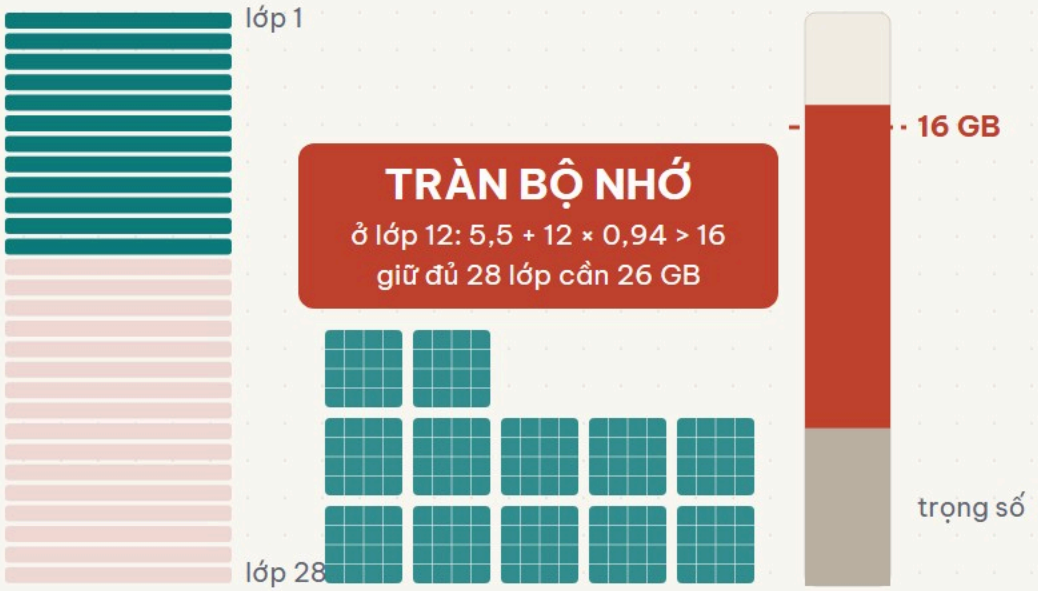
Một **hồi quy logistic** 579 tham số đổi 192 con số thành ba xác suất. Câu về Hồ Hoàn Kiếm có cụm "trở về dinh thự" tự bịa: rủi ro **0,997**.

Mô hình đọc: Qwen2.5 (Qwen Team, 2024) · ví dụ thật: câu hỏi Hồ Hoàn Kiếm · mục 4.1, 4.2, 4.7

Giữ ma trận của cả 28 lớp thì tràn bộ nhớ; tính xong lớp nào xóa lớp đó thì vừa một card T4

THUẬT NGỮ **Forward hook** — một hàm nhỏ gắn vào mỗi lớp của mô hình, tự chạy ngay khi lớp đó tính xong.

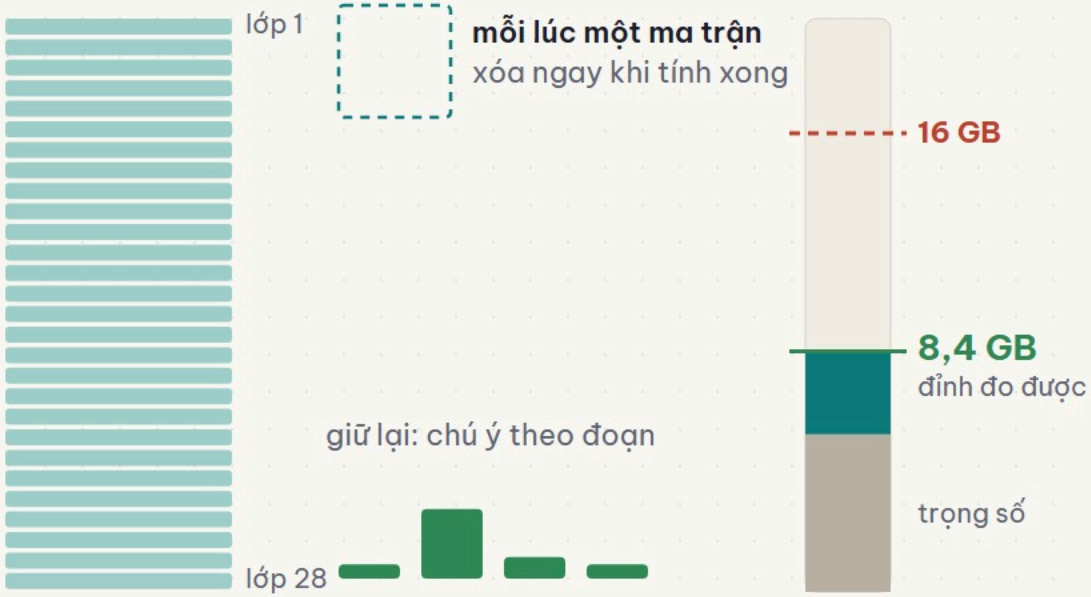
Cách thông thường



Qwen2.5-7B · 4.096 token

> 16 GB

Dùng forward hook



Qwen2.5-7B · 4.096 token

8,4 GB

Bộ nhớ đỉnh đo thực tế trên Tesla T4 ở ngưỡng 4.096 token là **8,4 GB** — mô hình 7B chạy trọn trong một card 16 GB miễn phí của Kaggle.

Vì sao không dùng được FlashAttention: Dao và cộng sự (NeurIPS 2022) · Bảng 2.2 và mục 4.8 · đỉnh 8.428 MB đo trên Tesla T4 ở ngưỡng 4.096 token

Đóng gói thành một hệ thống dùng được ngay: thư viện, dịch vụ REST, Docker và giao diện

Phục vụ — serve
thư viện Python · REST · Docker · giao diện web

Bộ phát hiện — detect
hồi quy logistic 579 tham số · tệp 11,5 KB

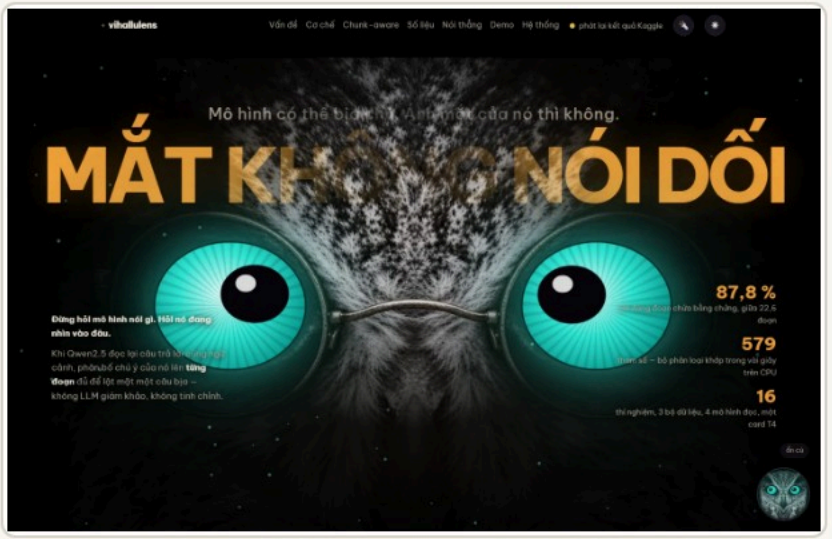
Đặc trưng — features
tỷ lệ nhìn lại + 5 hình dạng · 32 đầu → 192 con số

Trích chú ý — extract
prompt cố định · forward hook · float16 bỏ lớp 27

Python `det.score(context, question, response)`

REST `POST /score → nhãn, xác suất, rủi ro`

Docker `docker compose up`



Giao diện web: dán ngữ cảnh và câu trả lời, xem rủi ro, chú ý theo đoạn

11,5 KB
kích thước bộ phát hiện

700 / 700
dự đoán trùng lúc thí nghiệm

688
ca kiểm thử tự động đạt

Bộ phát hiện chỉ **11,5 KB**; nạp lại chấm 700 mẫu kiểm tra trùng **700/700** với lúc thí nghiệm.

Chạy thật: hệ thống tự bắt được câu bịa về Hồ Hoàn Kiếm

THUẬT NGỮ **Điểm rủi ro** — 1 trừ xác suất câu trả lời trung thực; càng gần 1 càng đáng ngờ.

Fansipan | Điện Biên Phủ | Phở | **Hồ Hoàn Kiếm**

Hồ Hoàn Kiếm gắn với truyền thuyết nào?

Tài liệu tìm được: Hà Nội · Tết Nguyên Đán · Tết Trung Thu

Qwen2.5-3B sinh câu trả lời

Hồ Hoàn Kiếm gắn với truyền thuyết về việc vua Lê Lợi trả gươm sau khi đánh đuổi giặc Minh. Truyền thuyết này nói rằng sau khi đánh đuổi giặc Minh, vua Lê Lợi đã đến hồ Hoàn Kiếm để trả gươm, sau đó anh ta đã trở về dinh thự.

Chú ý theo từng câu ngữ cảnh



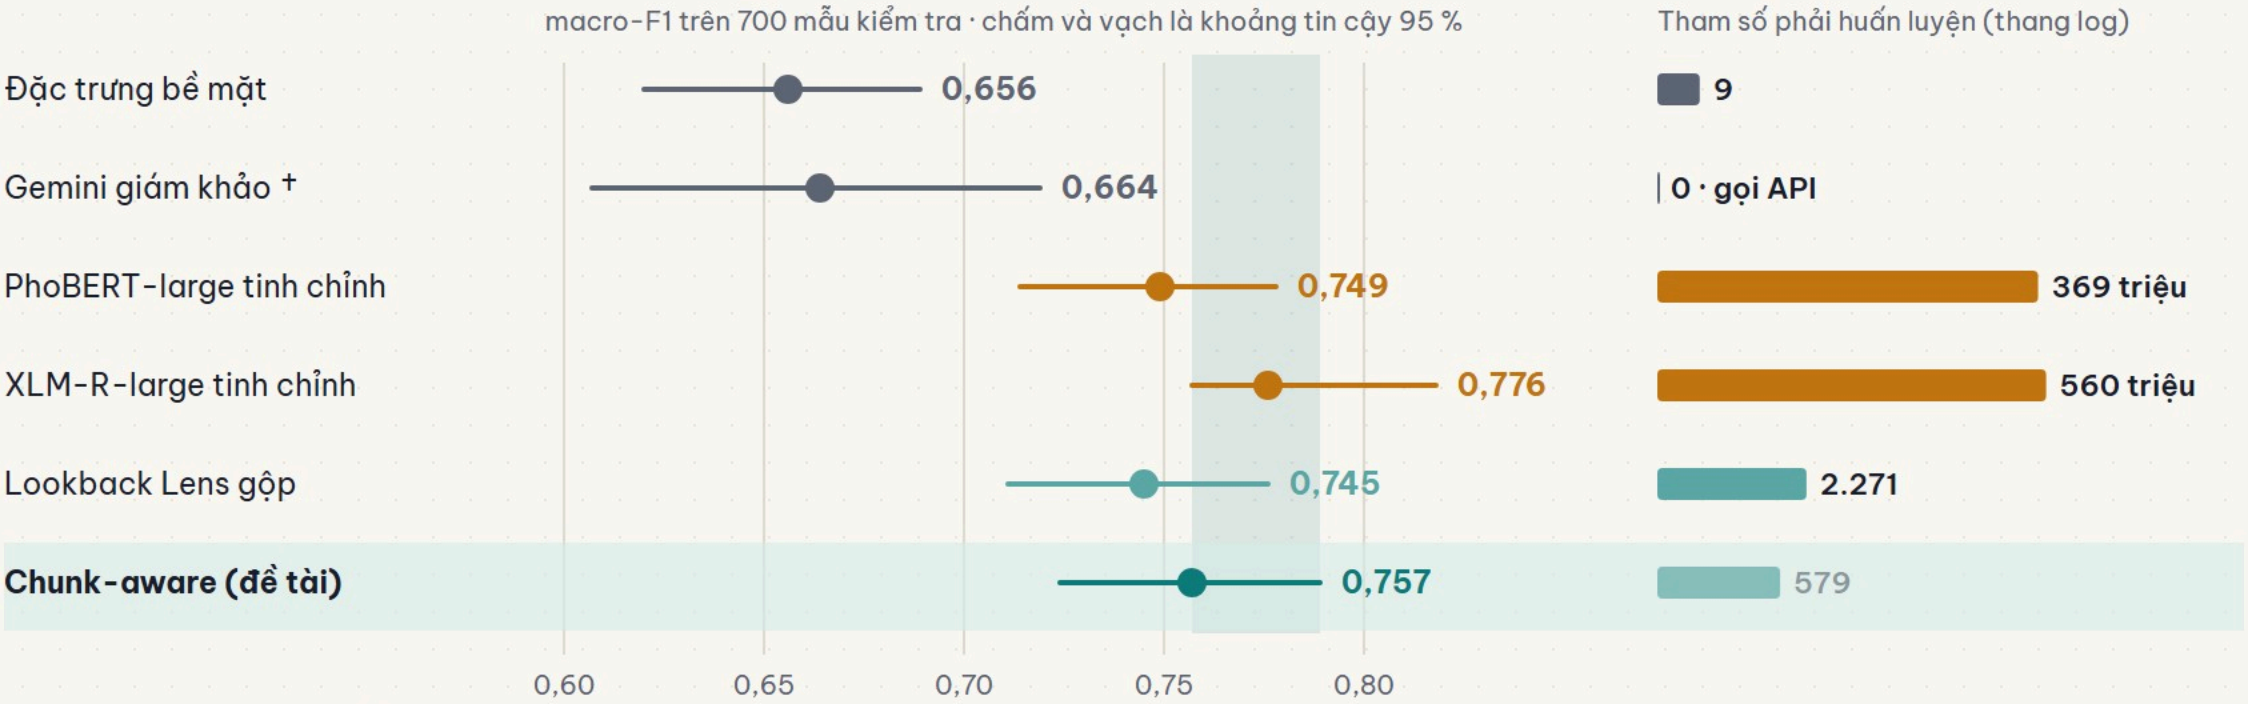


Bộ phát hiện tự chấm: **ngoại lai**, rủi ro **0,997**. Không ai viết sẵn câu trả lời — mô hình tự bịa, hệ thống tự bắt.

Dữ liệu thật, Kaggle T4, 11/09/2026 · truy xuất BM25: Robertson và Zaragoza (2009) · mục 5.6

Chỉ một bộ phân loại tuyến tính trên chú ý đã ngang PhoBERT được tinh chỉnh toàn bộ

THUẬT NGỮ **macro-F1** — điểm từ 0 đến 1, trung bình cộng điểm F1 của ba lớp; đoán bừa được khoảng 0,33. **Khoảng tin cậy 95 %** — vùng điểm có thể dao động nếu đổi tập kiểm tra.



† Gemini chấm trên 300/700 mẫu test

Khác biệt nằm ở cột phải: hướng chú ý chỉ huấn luyện **579 tham số**, ít hơn PhoBERT khoảng **638.000 lần**, và không phải tinh chỉnh mô hình nào.

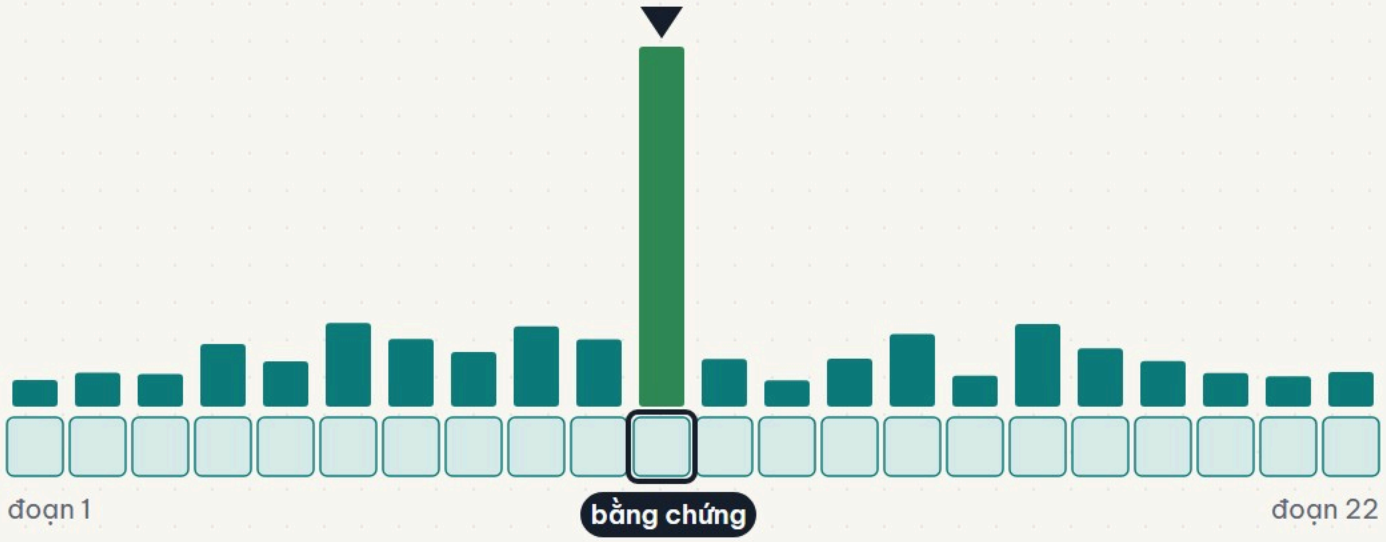
Bảng 6.1 · tập kiểm tra ViHallu 700 mẫu · PhoBERT: Nguyen và Nguyen (2020) · XLM-R: Conneau và cộng sự (2020) · LLM giám khảo: Zheng và cộng sự (2023)

Mô hình nhìn đúng đoạn chứa bằng chứng ở 87,8 % số mẫu

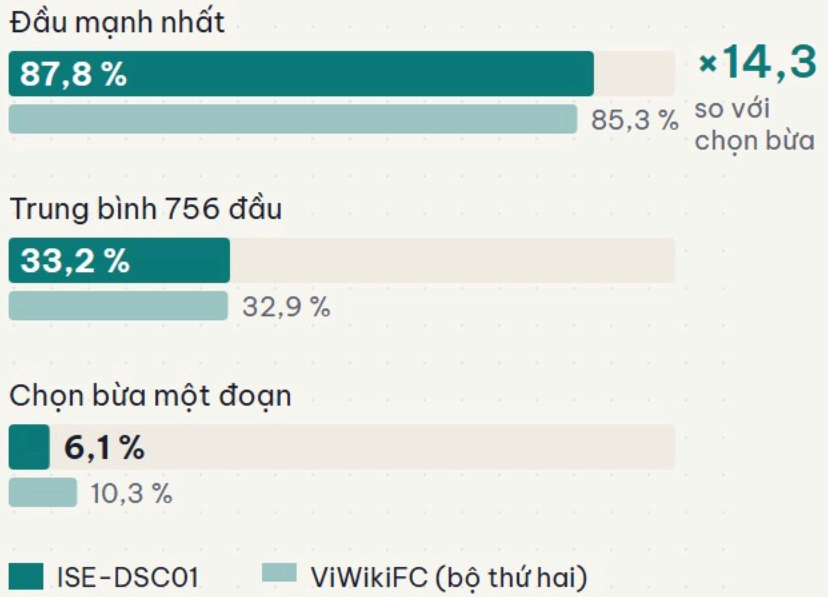
THUẬT NGỮ **Đầu chú ý (head)** — mỗi lớp có 28 phép chú ý chạy song song, mỗi phép là một đầu; đề tài xét đủ 27 × 28 = 756 đầu.

Mẫu khác ↻

Minh họa một mẫu ISE-DSC01: 22 đoạn, chú ý của đầu mạnh nhất (lớp 14, đầu 6) **trúng ✓**



Tỷ lệ trúng đoạn bằng chứng



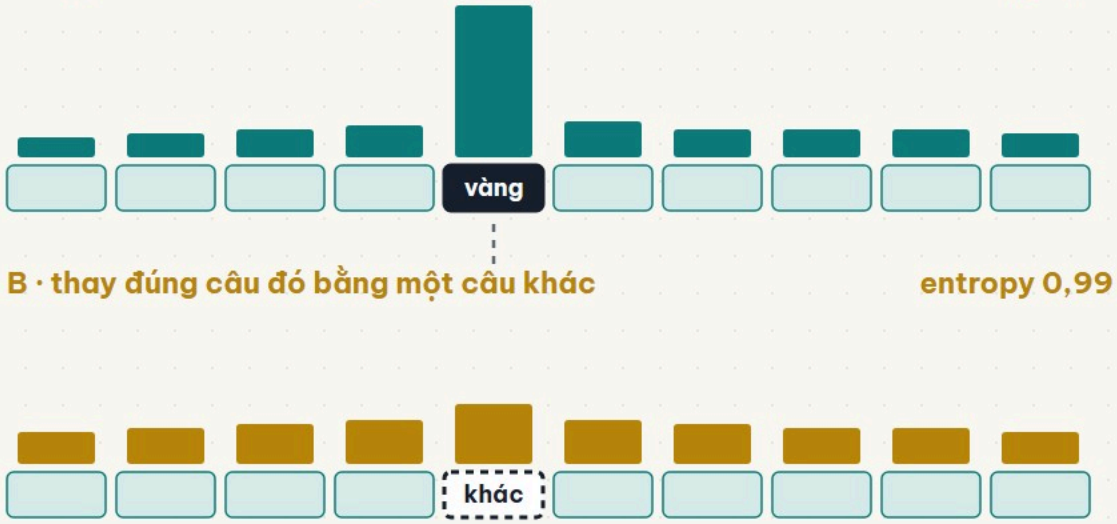
Lặp lại trên bộ thứ hai (ViWikiFC): trung bình mọi đầu **32,9 %** so với 33,2 %. Khả năng nhìn đúng chỗ thuộc về mô hình, không phụ thuộc bộ dữ liệu.

Bảng 6.3 và 6.7 · 2.376 mẫu ISE-DSC01 · tranh luận "chú ý có phải lời giải thích": Jain và Wallace (2019); Wiegreffe và Pinter (2019)

Rút câu bằng chứng ra thì chú ý tản ra — đúng như dự đoán ghi sẵn trước khi chạy

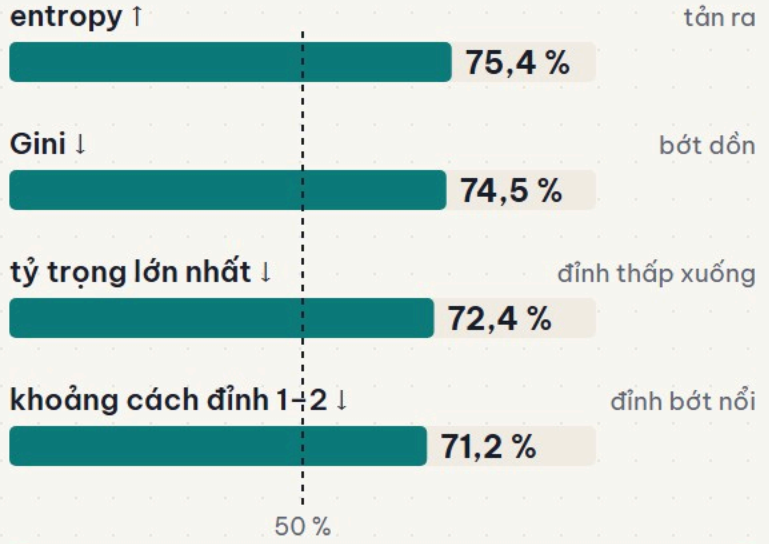
THUẬT NGỮ **Thí nghiệm can thiệp** — giữ nguyên mọi thứ, chỉ thay đúng một yếu tố, rồi đo lại để xem tín hiệu có phản ứng không.

Minh họa: cùng một câu khẳng định, đọc hai lần trên hai ngữ cảnh mười câu



A · có bằng chứng | B · đã thay | **Cả hai**

Tỷ lệ cặp đổi đúng hướng dự đoán
1.836 cặp ViWikiFC · 50 % là ngẫu nhiên



DỰ ĐOÁN GHI TRƯỚC KHI CHẠY · ĐÚNG 4/4

Hướng thay đổi được **ghi trong mã trước khi chạy**, nên đây không phải giải thích sau khi đã thấy số. Đặc trưng hình dạng phản ứng đúng với bằng chứng.

Bảng 6.6 · 1.836 cặp ViWikiFC (Le và cộng sự, 2024) · hướng dự đoán ghi trong mã trước khi chạy

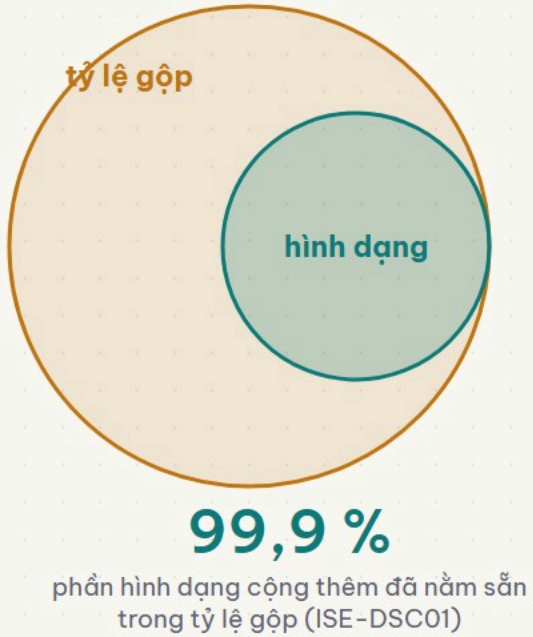
Nhưng thêm các đặc trưng hình dạng không làm điểm phân loại tăng lên

THUẬT NGỮ **Vùng nhiễu** — chênh lệch nhỏ hơn mức dao động tự nhiên của điểm số thì không thể kết luận là hơn hay kém.

Chênh macro-F1: chunk-aware trừ Lookback Lens gộp



Vì sao: hai nhóm mang cùng một tín hiệu



99,9 %

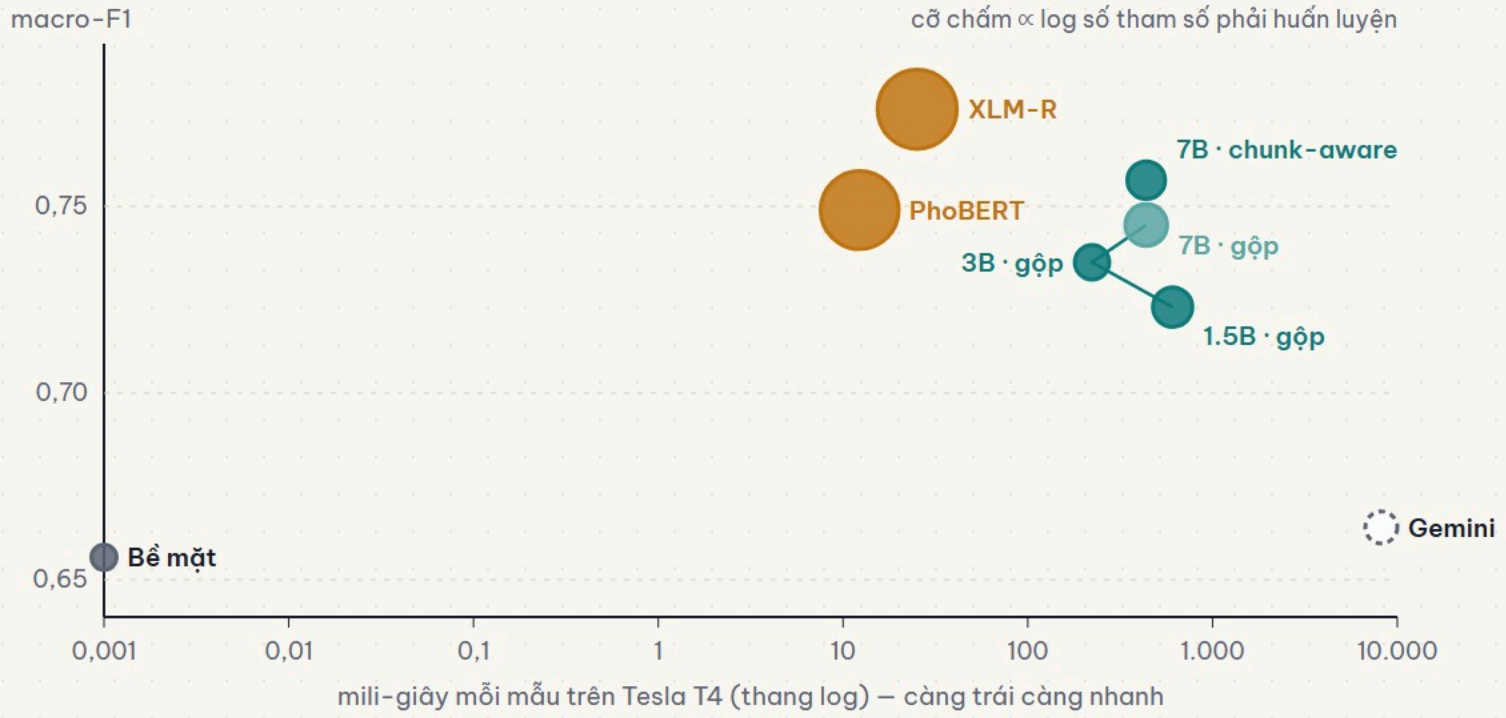
phần hình dạng cộng thêm đã nằm sẵn trong tỷ lệ gộp (ISE-DSC01)

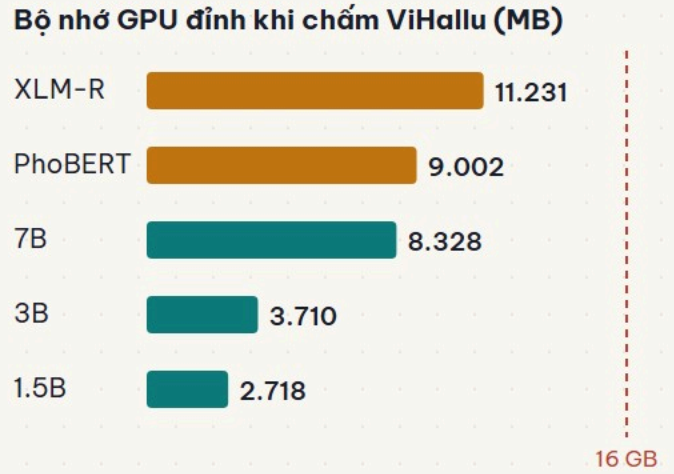
Trên ISE-DSC01, **99,9 %** phần hình dạng cộng thêm đã nằm trong tỷ lệ gộp. Nhóm báo cáo thẳng kết quả âm này thay vì chọn con số đẹp.

Bảng 6.2, 6.8, 6.9, 6.10, 6.12 · Sailor2: Dou và cộng sự (2025)

Thu mô hình đọc từ 7B xuống 3B: nhanh gấp đôi, nhẹ hơn một nửa, chỉ mất 0,01 điểm

THUẬT NGỮ **7B, 3B, 1.5B** — số tỷ tham số của mô hình đọc; mô hình càng nhỏ càng nhẹ.





Nghịch lý 1.5B: nhỏ nhất nhưng chậm hơn cả 7B. Ở float16 nó tràn số mọi lớp nên phải chạy **bfloat16** — T4 không hỗ trợ sẵn, chậm **4,1 lần**.

Về bộ nhớ, 3B chỉ cần **3,7 GB** — chạy được trên GPU phổ thông.

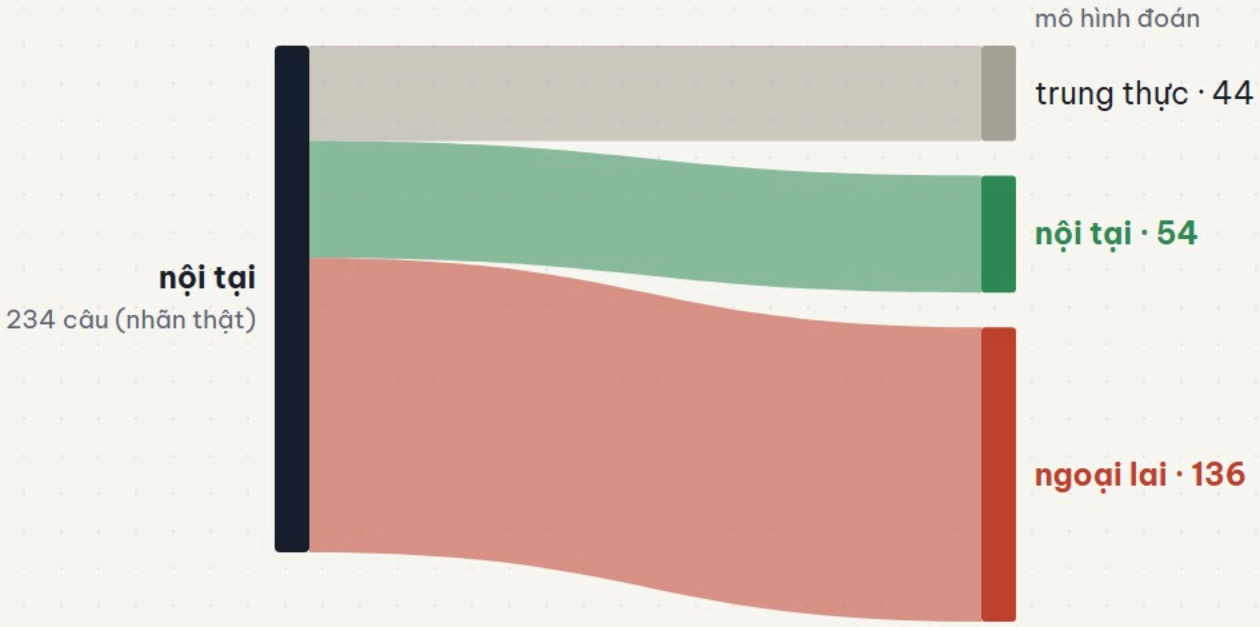
Bảng 6.10 và 6.14 · thời gian đo xen kẽ trên Tesla T4

Phân biệt "đúng hay sai" dùng lại được trên bộ dữ liệu khác; phân biệt "sai kiểu nào" thì không

THUẬT NGỮ **Chéo bộ** — huấn luyện trên bộ dữ liệu này, kiểm tra trên bộ dữ liệu kia.

ViHallu → ISE | ISE → ViHallu

Huấn luyện ISE-DSC01 → chấm ViHallu



macro-F1 khi chấm chéo bộ



Cùng tên lớp, khác định nghĩa

- "Ngoại lai" của ViHallu: nội dung GPT-4o **tự thêm vào** câu trả lời.
- "Ngoại lai" của ISE-DSC01: phát biểu NEI **do người viết**, ngữ cảnh không đủ để xác nhận.
- Điều **chuyển được** là "có bám ngữ cảnh hay không"; điều không chuyển được là "ảo giác loại nào".

Nguyên nhân khả dĩ nằm ở **định nghĩa nhãn** của hai bộ: cùng tên lớp nhưng tạo ra theo hai cách khác nhau.

Bảng 6.13 · nhãn SUPPORTED/REFUTED/NEI theo FEVER (Thorne và cộng sự, 2018)

Tự đánh giá: đã làm được gì, chưa làm được gì, và hướng tiếp theo

Đã làm được

- ✓ Bộ phát hiện ba lớp cho tiếng Việt từ tín hiệu chú ý: **0,757**, ngang bộ mã hóa tinh chỉnh với **579** tham số.
- ✓ Kiểm chứng trực tiếp cơ chế: nhìn đúng đoạn bằng chứng **87,8 %**, lặp lại trên bộ thứ hai, can thiệp đúng 4/4 hướng.
- ✓ Đo chi phí đầy đủ: mô hình 3B là điểm cân bằng, chỉ **195** tham số phải huấn luyện.
- ✓ Hệ thống hoàn chỉnh: thư viện, REST, Docker, giao diện; chạy thật bắt được ảo giác.

Chưa làm được

- – Năm đặc trưng hình dạng **không** làm tăng điểm phân loại so với tỷ lệ gộp.
- – Bộ phát hiện ba lớp không dùng được chéo bộ; chỉ quyết định nhị phân chuyển được.
- – Chi phí biên trong hệ RAG tự giám sát chưa đo: trên T4, mô hình sinh và mô hình đọc là hai mô hình.
- – Chưa chạy chuyển miền với ViFactCheck; Docker chưa kiểm trên máy có GPU.

Hướng phát triển

- → Chấm theo từng mệnh đề: lấy trung bình trên cả câu trả lời làm loãng một mệnh đề bịa.
- → Kết hợp chú ý với bộ mã hóa: chú ý mạnh ở lớp nội tại, bộ mã hóa mạnh ở lớp ngoại lai.
- → Đo chi phí biên khi một mô hình vừa sinh vừa đọc, trên phần cứng có bfloat16 gốc.
- → Chỉ tính hàng chú ý của token phản hồi, để dùng ngữ cảnh dài hơn 4.096 token.

Cảm ơn quý thầy cô *đã lắng nghe*

Nguyễn Ngọc Lân · Nguyễn Tấn Minh
Giảng viên hướng dẫn: ThS. Trương Vĩnh Linh
Mã nguồn: github.com/wsunicorn/vihallulens

Industrial University of Ho Chi Minh City